

# < MLE, Maximum Likelihood Estimation >

$\theta(\theta) = (\mu, \sigma) = (\text{평균}, \text{표준편차})$  이를 알고 있다면 **꼭 이때는 정답 보기가 1개.**

해당 도본이 발생할 확률값  $P(x|\theta)$  을 추정가능하고 가장 높은 것을 찾는게 MLE.

$N$ 개의 도본이 있고, 도본 데이터는 동일한 정규 분포로부터 뽑혔고, 도본이 뽑히는 과정이 서로 독립적이라고 가정.

**무도함수**  $= L(\theta, x_1, x_2, \dots, x_n) = P(x_1, \dots, x_n | \theta) = \prod_{i=1}^N N(x_i | \mu, \sigma^2)$  **여기서의 의미는 pdf의 MLE의 실명을 읽으면 여러개 가능.**

# < Gaussian Mixture Model >

\*  $k$  : 전체 데이터 세트를  $k$ 개의 Gaussian distribution을 분할하여 표현.

- \*  $\sigma_k$ 의 조건
- ①  $0 \leq \sigma_k < 1$
- ②  $\sum_{k=1}^K \sigma_k = 1$

주어진 데이터  $x$ 에 대하여 GMM은  $x$ 가 발생할 확률 :  $P(x) = \sum_{k=1}^K \sigma_k N(x | \mu_k, \Sigma_k)$

\*  $\sigma_k$  : GMM에서  $k$ 번째 Gaussian distribution의 표준 편차 **(여기서의 의미는 k번째 가우시안 분포가 선택될 확률과 k번째 가우시안 분포의 평균과 표준 편차에서  $x$ 가 등장한 급의 함.)**

\*  $\pi_k$  : mixing coefficient (분할 계수),  $k$ 번째 Gaussian distribution이 선택될 확률.

$\Rightarrow$  GMM을 학습시킨다는 것은 주어진 데이터  $X = \{x_1, x_2, \dots, x_n\}$ 에 대하여 적절한  $\pi_k, \mu_k, \Sigma_k$ 를 추정.

$\Rightarrow$  우리가 구하려고하는 것은  $k$ 개의 Gaussian distribution에 대해서 parameter, 총  $3 \times k$  (parameter를 구했다는 것은 해당 Gaussian model을 정의한 것과 마찬가지로이며, 뒤의 EM 알고리즘은 반복을 통하여 이를 구한다.)

# < GMM을 이용한 Classification >

주어진 데이터  $x_n$ 에 대하여 이 데이터가 어떠한 Gaussian distribution에서 생성되었는지를 찾는 것 이를 위해 필요한 것이 responsibility : 어떤 데이터가 속해있어 있는 distribution을 최종 결정하는 것.

responsibility  $= r(z_{nk}) = P(z_{nk}=1 | x_n)$   **$x_n$ 이 선택되었는지에  $z_{nk}$ 이 속함.**

$z_{nk} \in \{0, 1\}$ 은  $x_n$ 이 주어진 경우 GMM의  $k$ 번째 Gaussian distribution이 선택되면 1, 아니면 0 즉,  $z_{nk} = 1$ 인 것은  $x_n$ 이  $k$ 번째 Gaussian distribution에서 생성.

GMM을 이용한 Classification은  $x_n$ 이 주어진 경우,  $k$ 개의  $r(z_{nk})$ 를 계산하여 가장 값이 높은 Gaussian distribution을 선택하는 것. 이를 베이지안 성리를 통해 구할 수 있다.

$$P(\theta|X) = \frac{\text{Likelihood} \cdot \text{A prior probability}}{\text{Marginal probability}} = \frac{P(X|\theta)p(\theta)}{P(X)}$$

- \*  $X$  : 관측된 데이터, Observation을 뜻한다. 우리가 갖고 있는건 이거다!! (머신러닝에서는 트레이닝 데이터...)
- \*  $\theta$  : Hypothesis를 말하는데 데이터를 통해 추정하고자 하는 값이 되겠다. classification문제에서는 각 discrete한 클래스가 될 수 있고 linear regression의 경우 추정하려고 하는 weight들이 될 수 있다. 그 외에 추정하고자 하는 모든 문제에서 추정하고자하는 target값이 된다.
- \* Marginal probability  $P(X)$  : 데이터  $X$  자체의 분포를 뜻한다.
- \* A prior probability(사전확률)  $P(\theta)$  : 사전에 가지고 있는 확률을 말한다. 이때  $\theta$ 는 mutually independent해야한다. 예를들어, "마늘이 파란 다"/"마늘이 파란지 않다" 이 두가지 가정은 독립이고 두 확률의 합이 1이 되어야한다. (사실적으로 hypothesis에 대한 지식이 없을 때는 그냥 hypothesis의 element들이 가질 확률이 모두 같다고 두자)
- \* Likelihood(우도)  $P(X|\theta)$  : hypothesis를 두고, 다사실해 어떤 가정을 한 상태의 데이터의 분포를 뜻한다.
- \* A posterior probability(사후확률)  $P(\theta|X)$  : observation이 주어졌을 때의 hypothesis의 분포를 뜻한다. 예같은 경우에는 데이터  $X$ 의 영향을 반영하는 예다.

$r(z_{nk})$

$= P(z_{nk}=1 | x_n)$

$$= \frac{P(z_{nk}=1) P(x_n | z_{nk}=1)}{\sum_{j=1}^K P(z_{nj}=1) P(x_n | z_{nj}=1)}$$

$$= \frac{\pi_k N(x_n | \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j N(x_n | \mu_j, \Sigma_j)}$$

$\pi_k$  와  $P(z_{nk}=1)$ 은  $k$ 번째 가우시안 분포가 선택될 확률.  $P(z_{nj}=1)$ 이  $\pi_j$ 로 치환.

< EM 알고리즘을 이용한 학습 >

EM 알고리즘 : iteration based algorithm을 통해 GMM의 parameter를 찾는 것

기댓값 최대화 알고리즘.

모수에 관한 추정값으로 로그가능도의 기댓값을 계산하는 기댓값( $E$ ) 문제와

이 기댓값을 최대화하는 보수 추정값들을 구하는 최대화 (M) 단계로 번갈아가면서 실행.

일반적으로 GMM은 주어진 데이터  $X = \{x_1, x_2, \dots, x_N\}$ 에 대해 EM 알고리즘을 적용하여 parameter인  $\pi, \mu, \sigma$ 를 추정.

parameter를 추정하기 위해 log-likelihood  $\ell(X; \theta)$ 를 정의.

$$\mathcal{L}(X; \theta) = \ln p(X | \pi, \mu, \Sigma) = \ln \left\{ \prod_{n=1}^N p(x_n | \pi, \mu, \Sigma) \right\} = \sum_{n=1}^N \ln \left\{ \prod_{k=1}^K x_k \mathcal{N}(x_k | \mu_k, \Sigma_k) \right\}$$

직관적으로 likelihood는 어떠한 모델에서 데이터  $X = \{x_1, x_2, \dots, x_n\}$ 가 생성되었을 확률을 의미.

계산의 편의성을 위해  $\log$ -likelihood를 사용하며  $\log$ -likelihood를 최대화하는  $\mu, \sigma^2$ 를 추정하는 것은 주어진 데이터  $X$ 를 가장 잘 표현하는 GMM을 구성하는 것과 동등한 의미.

→ 이를 위해 각각의  $\mu_k, \sigma_k, \tau_k$ 에 대해 2를 편미분

⇒ 최대화 = 미분 값이 0 일 때.

 $\mu_k$ 에 대하여 정의함.

$$\frac{\partial \hat{z}(X; \theta)}{\partial \mu_k} = \sum_{n=1}^N \frac{\pi_k N(x_n | \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j N(x_n | \mu_j, \Sigma_j)} \Sigma_k^{-1} (x_n - \mu_k) = 0$$

$$\Leftrightarrow \sum_{n=1}^N \gamma(z_n, k) (x_n - \mu_k) = 0$$

이분을 뵈을 때 어떻게 이렇게 나왔는지 공부했는데  
이해가 안해서 적을 첨부합니다.

$$\therefore \mu_k = \frac{\sum_{n=1}^N \gamma(z_{nk}) x_n}{\sum_{n=1}^N \gamma(z_{nk})} \quad (7)$$

\*  $\Sigma_k$ 에 대하여 권미분.

$$\frac{\partial \mathcal{L}(X; \theta)}{\partial \Sigma_k} = \sum_{n=1}^N \frac{\pi_k N(x_n | \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j N(x_n | \mu_j, \Sigma_j)} \left\{ \frac{1}{2} \Sigma_k^{-1} (x_n - \mu_k)(x_n - \mu_k)^T \Sigma_k^{-1} - \frac{1}{2} \Sigma_k^{-1} \right\} = 0$$

$$\Leftrightarrow \sum_{n=1}^N \gamma(z_{nk}) \{ \Sigma_k^{-1} (x_n - \mu_k)(x_n - \mu_k)^T - 1 \} = 0$$

이 부분만

↳ 이 부분은 이해... 잘 안돼서  
이제까지 헛물켜였습니디.

$$\therefore \Sigma_k = \frac{\sum_{n=1}^N \gamma(z_{nk}) (x_n - \mu_k)(x_n - \mu_k)^T}{\sum_{n=1}^N \gamma(z_{nk})} \quad (8)$$

\*  $\pi_k$ 에 대하여 편미분. (이제라 잘 안돼서 식에 대한 설명은 생략하겠습니다... ㅜ)

$\pi_k$ 는  $\sum_{k=1}^K \pi_k = 1$ 의 조건을 만족하면서 log-likelihood를 최대화해야 한다. 따라서  $\pi_k$ 는 라그랑주 승수법을 이용하여 추정하며

라그랑지안  $J(X; \theta, \lambda)$ 는 다음과 같다.

$$J(X; \theta, \lambda) = \sum_{n=1}^N \ln \sum_{k=1}^K \pi_k N(x_n | \mu_k, \Sigma_k) + \lambda \left( 1 - \sum_{k=1}^K \pi_k \right) \quad (9)$$

$J(X; \theta, \lambda)$ 를  $\pi_k$ 에 대해 편미분하면  $\lambda$ 를 구할 수 있다.

$$\begin{aligned} \frac{\partial J(X; \theta, \lambda)}{\partial \pi_k} &= \sum_{n=1}^N \frac{N(x_n | \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j N(x_n | \mu_j, \Sigma_j)} - \lambda = 0 \\ \Leftrightarrow \sum_{k=1}^K \sum_{n=1}^N \frac{\pi_k N(x_n | \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j N(x_n | \mu_j, \Sigma_j)} - \lambda \sum_{k=1}^K \pi_k &= 0 \\ \Leftrightarrow \sum_{k=1}^K \sum_{n=1}^N \gamma(z_{nk}) - \lambda &= 0 \quad \left( \because \sum_{k=1}^K \pi_k = 1 \right) \end{aligned}$$

$$\therefore \underbrace{\lambda = N} \quad \left( \because \sum_{k=1}^K \gamma(z_{nk}) = 1 \right) \quad (10)$$

$\lambda = N$ 을 대입하여  $\pi_k$ 를 추정할 수 있다.

$$\begin{aligned} \frac{\partial J(X; \theta, \lambda)}{\partial \pi_k} &= \sum_{n=1}^N \frac{N(x_n | \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j N(x_n | \mu_j, \Sigma_j)} - N \stackrel{?}{=} 0 \\ \Leftrightarrow \sum_{n=1}^N \frac{\pi_k N(x_n | \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j N(x_n | \mu_j, \Sigma_j)} - N \pi_k &= 0 \end{aligned}$$

$$\therefore \pi_k = \frac{1}{N} \sum_{n=1}^N \gamma(z_{nk}) \quad (11)$$

EM의 parameter 추정을 위한 EM 알고리즘의 E-step에서는 모든 데이터와 Gaussian distribution에 대해 responsibility인  $r(z_{nk})$ 를 계산하고 M-step에서는 노란색 보름찬 식들  $[\mu, \sigma, \pi]$ 를 이용하여 모든 Gaussian distribution에 대한  $\mu, \sigma, \pi$ 를 추정한다. 이러한 E-step과 M-step을 선정한 횟수 또는 특정 값으로 수렴할 때까지 반복한다.